



รายงาน

เรื่อง EDA - Scopus Data

จัดทำโดย

นางสาวภัทราธิษฐ์ พรหมนัส 66011212201

นายจิรายุ จำปา 67011212082

นายวัชรพล จันทร์เพ็ง 67011212099

นายศุภกิตติ เวลุนารักษ์ 67011212193

รายงานนี้เป็นส่วนหนึ่งของรายวิชา วิทยาศาสตร์ข้อมูล

ภาคเรียนที่ 1 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาการสารสนเทศ มหาวิทยาลัยมหาสารคาม

คำนำ

รายงานฉบับนี้จัดทำขึ้นเพื่อศึกษาและวิเคราะห์ข้อมูลบทความวิจัยจากฐานข้อมูล Scopus โดยประยุกต์ใช้กระบวนการ Exploratory Data Analysis (EDA) เพื่อสำรวจโครงสร้าง ลักษณะ คุณภาพ การกระจายตัว และความสัมพันธ์ของข้อมูลในมิติต่าง ๆ รวมถึงการนำเสนอผลการวิเคราะห์ด้วย Data Visualization เพื่อช่วยให้สามารถทำความเข้าใจข้อมูลได้อย่างเป็นระบบและชัดเจนยิ่งขึ้น

การวิเคราะห์ข้อมูลในรายงานฉบับนี้ใช้ข้อมูลบทความวิจัยจำนวน 6,000 บทความ ครอบคลุม 10 Subjects โดยแบ่งการวิเคราะห์ออกเป็น 5 มิติ ได้แก่ NLP & Language, Temporal Trends, Publication & Venues, Collaboration และ ML Readiness ซึ่งครอบคลุมตั้งแต่การวิเคราะห์ข้อมูลข้อความ แนวโน้มของงานวิจัยตามช่วงเวลา รูปแบบการเผยแพร่ ความร่วมมือของผู้เขียน ตลอดจนการประเมินความพร้อมของข้อมูลสำหรับนำไปใช้ใน Machine Learning

นอกจากการทำ EDA แล้ว รายงานฉบับนี้ยังนำผลจากการวิเคราะห์มาประกอบประกอบการคัดเลือกข้อมูลข้อความที่มีความสำคัญเชิง Semantic ได้แก่ Title, Abstract, Author Keywords และ Index Keywords เพื่อนำไปสร้าง Text Embedding ด้วยโมเดล SPECTER2 และแปลงบทความให้อยู่ในรูปแบบ Feature Vector ซึ่งสามารถนำไปใช้เป็นข้อมูลสำหรับงาน Machine Learning ในขั้นตอนต่อไป

ผู้จัดทำหวังว่ารายงานฉบับนี้จะช่วยให้ผู้อ่านเข้าใจกระบวนการ Exploratory Data Analysis การเลือกใช้ Data Visualization การวิเคราะห์และตีความข้อมูล ตลอดจนแนวทางการเตรียมข้อมูลข้อความสำหรับสร้าง Text Embedding และ Feature Vector หากรายงานฉบับนี้มีข้อผิดพลาดหรือข้อบกพร่องประการใด ผู้จัดทำขอน้อมรับคำแนะนำและข้อเสนอแนะเพื่อนำไปปรับปรุงให้มีความถูกต้องและสมบูรณ์ยิ่งขึ้นต่อไป

ผู้จัดทำ

คณะผู้จัดทำรายงาน

สารบัญ

คำนำ	1
สารบัญ	2
บทที่ 1 บทนำ	5
1.1 ที่มาและความสำคัญ	5
1.1 วัตถุประสงค์.....	5
1.2 ขอบเขตของการศึกษา.....	5
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	8
2.1 ฐานข้อมูล Scopus	8
2.2 Exploratory Data Analysis.....	8
2.3 Data Visualization	8
2.4 Natural Language Processing.....	9
2.5 Keyword Analysis.....	9
2.6 Jaccard Similarity	9
2.7 Type-Token Ratio.....	10
2.8 Bigram	10
2.9 Temporal Analysis	10
2.10 Citation	10
2.11 Collaboration และ Author Count.....	10
2.12 Text Embedding.....	11
2.13 Feature Vector.....	11

2.14 SPECTER2	11
2.15 Transformer และ Tokenization	11
2.16 t-SNE.....	12
2.17 Machine Learning	12
บทที่ 3 วิธีการดำเนินงาน.....	13
3.1 ภาพรวมการดำเนินงาน.....	13
3.2 ข้อมูลที่ใช้.....	13
3.3 การทำ Exploratory Data Analysis.....	14
3.4 การสร้าง Data Visualization	14
3.5 การวิเคราะห์และตีความ Visualization	16
3.6 การคัดเลือกข้อมูลสำหรับ Text Embedding.....	16
3.7 การรวมข้อมูลข้อความ	17
3.8 การกำหนดความยาวของข้อความ.....	17
3.9 การสร้าง Text Embedding.....	17
3.10 การจัดเก็บ Feature Vector	18
3.11 การตรวจสอบผลลัพธ์.....	18
บทที่ 4 ผลการดำเนินงาน	19
4.1 ผลการวิเคราะห์ข้อมูลเบื้องต้น	19
4.2 ผลการวิเคราะห์ด้าน NLP & Language	19
4.3 ผลการวิเคราะห์ด้าน Temporal Trends	20
4.4 ผลการวิเคราะห์ด้าน Publication & Venues.....	20

4.5 ผลการวิเคราะห์ด้าน Collaboration.....	21
4.6 ผลการวิเคราะห์ด้าน ML Readiness.....	21
4.7 ผลการคัดเลือกข้อมูลสำหรับ Text Embedding	22
4.8 ผลการสร้าง Text Embedding.....	23
4.9 ผลการตรวจสอบ Feature Vector.....	23
4.10 สรุปผลการดำเนินงาน.....	23

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญ

ในปัจจุบันมีการเผยแพร่บทความวิจัยทางด้านวิทยาการคอมพิวเตอร์และเทคโนโลยีสารสนเทศเป็นจำนวนมาก ส่งผลให้เกิดข้อมูลทางวิชาการที่มีความหลากหลาย ทั้งด้านเนื้อหา สาขาวิชา ปีที่เผยแพร่ แหล่งตีพิมพ์ ผู้เขียน คำสำคัญ และจำนวนการอ้างอิง ข้อมูลเหล่านี้สามารถนำมาวิเคราะห์เพื่อทำความเข้าใจลักษณะของงานวิจัย รวมถึงค้นหารูปแบบและความสัมพันธ์ที่ปรากฏอยู่ภายในข้อมูลได้

งานนี้ศึกษาข้อมูลบทความวิจัยใน 10 สาขาวิชาหลัก ได้แก่ Artificial Intelligence, Computational Theory and Mathematics, Computer Graphics and Computer-Aided Design, Computer Networks and Communications, Computer Vision and Pattern Recognition, Hardware and Architecture, Human-Computer Interaction, Information Systems, Signal Processing และ Software โดยแต่ละสาขามีลักษณะเนื้อหาและแนวทางการวิจัยที่แตกต่างกัน การวิเคราะห์ข้อมูลทั้ง 10 สาขาวิชาจึงช่วยให้สามารถเปรียบเทียบความเหมือน ความแตกต่าง และความสัมพันธ์ระหว่างสาขาวิชาได้อย่างเป็นระบบ

1.1 วัตถุประสงค์

1. ศึกษาและอธิบายกระบวนการทำ EDA
2. ศึกษาและอธิบายการทำ Visualization ที่สร้างแต่ละตัวและความสัมพันธ์กับข้อมูล
3. สรุปข้อมูลที่จะนำไปทำ Text Embedding

1.2 ขอบเขตของการศึกษา

การวิเคราะห์ครั้งนี้ใช้ข้อมูลจาก scopus จำนวน 6,000 บทความ แบ่งเป็น 10 Subjects ได้แก่

1. Artificial Intelligence
2. Computational Theory and Mathematics
3. Computer Graphics and Computer-Aided Design

4. Computer Networks and Communications
5. Computer Vision and Pattern Recognition
6. Hardware and Architecture
7. Human-Computer Interaction
8. Information Systems
9. Signal Processing
10. Software

แต่ละ Subject มีจำนวน 600 บทความ รวมทั้งหมด 6,000 บทความ

ขอบเขตการวิเคราะห์แบ่งออกเป็น 5 มิติ ได้แก่

1. **NLP & Language**

วิเคราะห์ลักษณะและความสัมพันธ์ของข้อมูลข้อความในแต่ละ Subject เช่น Keywords ความหลากหลายของคำศัพท์ และคำหรือวลีที่ปรากฏบ่อย รวมถึงเปรียบเทียบความคล้ายของเนื้อหาระหว่าง 10 Subjects

2. **Temporal Trends**

วิเคราะห์แนวโน้มของบทความและ Keywords ตามช่วงเวลา รวมถึงการกระจายของ Citation ตามปีที่ตีพิมพ์ และเปรียบเทียบแนวโน้มระหว่างแต่ละ Subject

3. **Publication & Venues**

วิเคราะห์ประเภทเอกสาร แหล่งตีพิมพ์ และความสัมพันธ์ระหว่าง Open Access กับ Citation ของบทความในแต่ละ Subject

4. **Collaboration**

วิเคราะห์จำนวนผู้เขียนและความสัมพันธ์ระหว่างจำนวนผู้เขียนกับจำนวนการอ้างอิง รวมถึงเปรียบเทียบรูปแบบความร่วมมือระหว่างสาขาวิชา

5. ML Readiness

วิเคราะห์ความสามารถในการแยกกลุ่มของข้อมูลข้อความ ความยาวของข้อความ และ Missing Value เพื่อประเมินความพร้อมก่อนนำข้อมูลไปใช้กับ Machine Learning

สำหรับการสร้าง Text Embedding จะพิจารณาข้อมูลข้อความ ได้แก่ Title, Abstract, Author Keywords และ Index Keywords โดยใช้ข้อมูลจากทั้ง 10 Subjects และนำผลลัพธ์ที่ได้มาใช้ในการสร้าง Feature Vector สำหรับ Machine Learning

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ฐานข้อมูล Scopus

Scopus เป็นฐานข้อมูลสำหรับรวบรวมและจัดทำดัชนีวรรณกรรมทางวิชาการ เช่น บทความวิจัย บทความจากการประชุม และแหล่งเผยแพร่ทางวิชาการอื่น ๆ โดยข้อมูลบทความสามารถประกอบด้วย รายละเอียดหลายประเภท เช่น ชื่อบทความ บทคัดย่อ คำสำคัญ ผู้เขียน แหล่งตีพิมพ์ ปีที่เผยแพร่ และข้อมูลการอ้างอิง

ข้อมูลจากฐานข้อมูลทางวิชาการสามารถนำมาวิเคราะห์เพื่อศึกษาลักษณะและแนวโน้มของงานวิจัยในแต่ละสาขา รวมถึงสามารถนำข้อมูลข้อความ เช่น Title, Abstract และ Keywords ไปใช้ในงานประมวลผลภาษาธรรมชาติและ Machine Learning ได้

2.2 Exploratory Data Analysis

Exploratory Data Analysis หรือ EDA เป็นกระบวนการสำรวจและทำความเข้าใจข้อมูลก่อนนำไปวิเคราะห์หรือสร้างแบบจำลอง โดยมีเป้าหมายเพื่อศึกษาลักษณะของข้อมูล ตรวจสอบคุณภาพข้อมูล ค้นหา รูปแบบ ความสัมพันธ์ และความผิดปกติที่อาจเกิดขึ้น

กระบวนการ EDA สามารถใช้วิธีการทางสถิติและ Data Visualization ร่วมกัน เพื่อช่วยให้ผู้วิเคราะห์ เข้าใจข้อมูลและสามารถตัดสินใจเกี่ยวกับการเตรียมข้อมูลสำหรับขั้นตอนถัดไปได้้อย่างเหมาะสม

สำหรับข้อมูลบทความวิจัย EDA สามารถใช้วิเคราะห์ได้ทั้งข้อมูลเชิงตัวเลข ข้อมูลเชิงหมวดหมู่ และข้อมูลข้อความ

2.3 Data Visualization

Data Visualization คือการนำข้อมูลมาแสดงในรูปแบบกราฟ แผนภาพ หรือรูปแบบภาพอื่น ๆ เพื่อช่วยให้ผู้วิเคราะห์สามารถมองเห็นรูปแบบ แนวโน้ม การกระจายตัว และความสัมพันธ์ของข้อมูลได้ง่ายกว่าการพิจารณาข้อมูลในรูปแบบตารางเพียงอย่างเดียว

การเลือก Visualization ควรสัมพันธ์กับประเภทของข้อมูลและวัตถุประสงค์ของการวิเคราะห์ เช่น Line Chart เหมาะสำหรับการแสดงแนวโน้มตามเวลา Box Plot เหมาะสำหรับการแสดงการกระจายของข้อมูล และ Heatmap สามารถใช้แสดงความสัมพันธ์หรือค่าความคล้ายระหว่างกลุ่มข้อมูล

2.4 Natural Language Processing

Natural Language Processing หรือ NLP เป็นสาขาที่เกี่ยวข้องกับการประมวลผลและวิเคราะห์ข้อมูลภาษาธรรมชาติด้วยคอมพิวเตอร์ โดยสามารถนำมาใช้กับข้อมูลข้อความ เช่น เอกสาร บทความวิจัย บทความย่อ และ คำสำคัญ

ในการวิเคราะห์บทความวิจัย NLP สามารถใช้เพื่อศึกษาความถี่ของคำ ความหลากหลายของคำศัพท์ ความสัมพันธ์ของคำ และลักษณะของข้อความในแต่ละสาขาวิชา

2.5 Keyword Analysis

Keywords เป็นคำหรือวลีที่ใช้สะท้อนหัวข้อหรือประเด็นสำคัญของเอกสาร การวิเคราะห์ Keywords สามารถช่วยให้เห็นหัวข้อที่เกี่ยวข้องกับบทความ และสามารถนำ Keywords ของบทความต่าง ๆ มาเปรียบเทียบ เพื่อศึกษาความคล้ายหรือความแตกต่างระหว่างกลุ่มข้อมูลได้

2.6 Jaccard Similarity

Jaccard Similarity เป็นวิธีการวัดความคล้ายระหว่างเซตสองเซต โดยพิจารณาสัดส่วนของสมาชิกที่มีร่วมกันเมื่อเทียบกับสมาชิกทั้งหมดของทั้งสองเซต สามารถคำนวณได้จาก

$$J(A,B) = |A \cap B| / |A \cup B|$$

ค่าที่ได้อยู่ระหว่าง 0 ถึง 1 โดยค่าที่เข้าใกล้ 1 หมายถึงมีความคล้ายหรือมีสมาชิกที่เหมือนกันมาก และค่าที่เข้าใกล้ 0 หมายถึงมีความแตกต่างกันมาก

ในการวิเคราะห์ข้อมูลบทความวิจัยสามารถนำ Jaccard Similarity มาใช้เปรียบเทียบชุด Keywords ระหว่าง Subjects

2.7 Type-Token Ratio

Type-Token Ratio หรือ TTR เป็นตัวชี้วัดความหลากหลายของคำศัพท์ในข้อความ โดยคำนวณจากอัตราส่วนระหว่างจำนวนคำที่ไม่ซ้ำกันกับจำนวนคำทั้งหมด $TTR = \text{จำนวนคำที่ไม่ซ้ำ} / \text{จำนวนคำทั้งหมด}$

ค่า TTR ที่สูงแสดงว่าข้อความมีความหลากหลายของคำศัพท์มากขึ้น ในขณะที่ค่าที่ต่ำแสดงว่ามีการใช้คำซ้ำมากกว่า

2.8 Bigram

Bigram คือกลุ่มของคำสองคำที่ปรากฏต่อเนื่องกันในข้อความ การวิเคราะห์ความถี่ของ Bigram สามารถใช้ค้นหาคู่คำหรือวลีที่ปรากฏบ่อย และช่วยให้เห็นรูปแบบการใช้ภาษาในข้อมูล ในข้อมูลบทความวิจัย Bigram สามารถใช้ค้นหาวลีที่มีความสำคัญหรือเป็นลักษณะเฉพาะของแต่ละสาขาวิชาได้

2.9 Temporal Analysis

Temporal Analysis คือการวิเคราะห์ข้อมูลตามช่วงเวลา โดยใช้ตัวแปรด้านเวลา เช่น ปีที่เผยแพร่ เพื่อศึกษาการเปลี่ยนแปลงของข้อมูล สำหรับข้อมูลบทความวิจัย Temporal Analysis สามารถใช้ศึกษาจำนวนบทความในแต่ละปี การเปลี่ยนแปลงของ Keywords และรูปแบบของ Citation ตามช่วงเวลา

2.10 Citation

Citation หรือการอ้างอิงเป็นข้อมูลที่ใช้แสดงจำนวนครั้งที่ผลงานวิจัยถูกนำไปอ้างอิงในงานวิจัยอื่น สามารถนำมาใช้เป็นตัวชี้วัดหนึ่งในการวิเคราะห์ผลกระทบหรือการได้รับความสนใจของบทความ

Citation สามารถนำไปวิเคราะห์ร่วมกับตัวแปรอื่น เช่น ปีที่ตีพิมพ์ จำนวนผู้เขียน หรือ Open Access เพื่อศึกษาความสัมพันธ์ของข้อมูล

2.11 Collaboration และ Author Count

ข้อมูลจำนวนผู้เขียนสามารถนำมาใช้วิเคราะห์รูปแบบการทำงานร่วมกันของนักวิจัย โดยสามารถพิจารณาการกระจายของจำนวนผู้เขียนในแต่ละ Subject และศึกษาความสัมพันธ์ระหว่างจำนวนผู้เขียนกับ Citation

2.12 Text Embedding

Text Embedding คือการแปลงข้อความให้อยู่ในรูปแบบเวกเตอร์ตัวเลขที่สามารถนำไปใช้ในกระบวนการประมวลผลข้อมูลและ Machine Learning ได้

แนวคิดสำคัญของ Text Embedding คือการแทนข้อความด้วยเวกเตอร์ในปริภูมิตัวเลข โดยข้อความที่มีความหมายใกล้เคียงกันมีแนวโน้มที่จะมีตำแหน่งอยู่ใกล้กันใน Vector Space

Text Embedding จึงสามารถนำไปใช้กับงาน เช่น Semantic Similarity, Classification, Clustering และ Information Retrieval

2.13 Feature Vector

Feature Vector คือชุดของค่าตัวเลขที่ใช้แทนคุณลักษณะของข้อมูลหนึ่งรายการ สำหรับข้อมูลข้อความ Feature Vector สามารถสร้างขึ้นจาก Text Embedding เมื่อบทความแต่ละบทความถูกแปลงเป็นเวกเตอร์แล้วสามารถนำเวกเตอร์ดังกล่าวมาเรียงเป็นเมทริกซ์เพื่อใช้เป็นข้อมูลนำเข้าสำหรับ Machine Learning ได้

2.14 SPECTER2

SPECTER2 เป็นโมเดลที่ออกแบบมาสำหรับสร้าง Representation ของเอกสารทางวิชาการ โดยสามารถใช้ข้อมูลข้อความของเอกสารเพื่อสร้างเวกเตอร์ที่สะท้อนความสัมพันธ์เชิงความหมายระหว่างเอกสาร

ในการสร้าง Text Embedding ของบทความวิจัย SPECTER2 สามารถใช้เป็นโมเดลสำหรับเปลี่ยนข้อมูลข้อความของบทความให้เป็น Feature Vector ที่สามารถนำไปใช้ในงานวิเคราะห์เอกสารทางวิชาการต่อไป

2.15 Transformer และ Tokenization

Transformer เป็นสถาปัตยกรรมของโมเดล Deep Learning ที่ถูกนำมาใช้ในงานประมวลผลภาษาธรรมชาติอย่างแพร่หลาย โดยสามารถประมวลผลความสัมพันธ์ระหว่างส่วนต่าง ๆ ของข้อความได้

ก่อนนำข้อความเข้าสู่โมเดล ข้อความจะถูกแปลงเป็น Tokens ด้วยกระบวนการ Tokenization โดยแต่ละ Token จะถูกแทนด้วยค่าที่โมเดลสามารถประมวลผลได้ เนื่องจากโมเดลมีข้อจำกัดด้านความยาวของ Input จึงต้องกำหนดความยาวสูงสุดของข้อความก่อนเข้าสู่โมเดล

2.16 t-SNE

t-SNE หรือ t-distributed Stochastic Neighbor Embedding เป็นวิธีการลดมิติข้อมูลที่ใช้สำหรับแสดงข้อมูลที่มีมิติสูงในพื้นที่ที่มีมิติต่ำ เช่น 2 มิติ t-SNE เหมาะสำหรับการสำรวจโครงสร้างของข้อมูลและตรวจสอบว่าข้อมูลมีแนวโน้มเกิดการรวมกลุ่มหรือไม่ โดยจุดข้อมูลที่อยู่ใกล้กันในพื้นที่ที่ลดมิติแล้วมีแนวโน้มที่จะมีลักษณะคล้ายกัน

ในการวิเคราะห์ข้อมูลบทความวิจัย t-SNE สามารถนำมาใช้แสดงการกระจายตัวของ Feature หรือ Text Embedding เพื่อสำรวจความสัมพันธ์ระหว่างบทความจากแต่ละ Subject

2.17 Machine Learning

Machine Learning เป็นกระบวนการที่ทำให้คอมพิวเตอร์สามารถเรียนรู้รูปแบบจากข้อมูลและนำรูปแบบดังกล่าวไปใช้ในการทำนายหรือวิเคราะห์ข้อมูลใหม่

สำหรับงานนี้ Feature Vector จาก Text Embedding สามารถนำไปใช้เป็นข้อมูลนำเข้าสำหรับ Machine Learning เช่น Classification และ Clustering โดยรูปแบบการใช้งานขึ้นอยู่กับวัตถุประสงค์ของการวิเคราะห์

บทที่ 3

วิธีการดำเนินงาน

3.1 ภาพรวมการดำเนินงาน

การดำเนินงานเริ่มจากการเตรียมข้อมูลบทความวิจัยจากฐานข้อมูล Scopus จากนั้นตรวจสอบและวิเคราะห์ข้อมูลด้วย Exploratory Data Analysis (EDA) เพื่อทำความเข้าใจลักษณะของข้อมูลและค้นหารูปแบบที่สำคัญ หลังจากนั้นจึงสร้าง Data Visualization เพื่ออธิบายผลการวิเคราะห์ในแต่ละด้าน และนำผลจาก EDA มาประกอบการตัดสินใจเลือกข้อมูลสำหรับสร้าง Text Embedding และ Feature Vector

3.2 ข้อมูลที่ใช้

ข้อมูลที่ใช้มาจาก Scopus ได้แก่

1. Artificial Intelligence
2. Computational Theory and Mathematics
3. Computer Graphics and Computer-Aided Design
4. Computer Networks and Communications
5. Computer Vision and Pattern Recognition
6. Hardware and Architecture
7. Human-Computer Interaction
8. Information Systems
9. Signal Processing
10. Software

แต่ละ Subject มีจำนวน 600 บทความ รวมทั้งหมด 6,000 บทความ

3.3 การทำ Exploratory Data Analysis

การทำ EDA แบ่งออกเป็น 5 Dimensions เพื่อวิเคราะห์ข้อมูลในมุมมองที่แตกต่างกัน ดังนี้

3.3.1 Dimension 1: NLP & Language

วิเคราะห์ข้อมูลข้อความและ Keywords เพื่อศึกษาความคล้ายของเนื้อหา ความหลากหลายของคำศัพท์ และคำหรือวลีที่ปรากฏบ่อย ประกอบด้วย Jaccard Similarity Heatmap, Type-Token Ratio และ Bigram Frequency

3.3.2 Dimension 2: Temporal Trends

วิเคราะห์แนวโน้มของบทความและข้อมูลที่เกี่ยวข้องกับเวลา โดยใช้ปีที่เผยแพร่เป็นตัวแปรหลัก ประกอบด้วย Publication Trend, Emerging Keywords และ Citation Velocity

3.3.3 Dimension 3: Publication & Venues

วิเคราะห์ลักษณะการเผยแพร่และแหล่งตีพิมพ์ของบทความ ประกอบด้วย Document Type Distribution, Top Publication Sources และ Open Access vs Citation

3.3.4 Dimension 4: Collaboration

วิเคราะห์ลักษณะการทำงานร่วมกันของผู้เขียน ประกอบด้วย Author Count Distribution และ Author Count vs Citation

3.3.5 Dimension 5: ML Readiness

วิเคราะห์ความพร้อมของข้อมูลก่อนนำไปใช้ใน Machine Learning และ Text Embedding ประกอบด้วย t-SNE Semantic Visualization, Token Length CDF และ Missing Value Analysis

3.4 การสร้าง Data Visualization

Visualization แต่ละตัวถูกเลือกตามลักษณะของข้อมูลและคำถามที่ต้องการวิเคราะห์ โดยมีรายละเอียดดังนี้

Visualization	แผนภูมิ	ข้อมูลที่ใช้	จุดประสงค์
Jaccard Similarity Heatmap	1	Keywords	เปรียบเทียบความคล้าย ของ Keywords ระหว่าง Subjects
TTR	2	Abstract	วิเคราะห์ความหลากหลาย ของคำศัพท์
Bigram Frequency	3	Abstract	วิเคราะห์คู่คำที่พบบ่อย
Publication Trend	4	Year, Subject	วิเคราะห์แนวโน้มจำนวน บทความ
Emerging Keywords	5	Keywords, Year	วิเคราะห์ Keywords ที่ เปลี่ยนแปลงตามเวลา
Citation Velocity	6	Year, Citation	วิเคราะห์รูปแบบ Citation ตามเวลา
Document Type Distribution	7	Document Type, Subject	เปรียบเทียบประเภท เอกสาร
Top Publication Sources	8	Publication Source	วิเคราะห์แหล่งตีพิมพ์
Open Access vs Citation	9	Open Access, Citation	เปรียบเทียบ Citation ตามสถานะ Open Access
Author Count Distribution	10	Author Count, Subject	วิเคราะห์การกระจาย จำนวนผู้เขียน
Author Count vs Citation	11	Author Count, Citation	วิเคราะห์ความสัมพันธ์ ระหว่างผู้เขียนกับ Citation
t-SNE	12	ข้อมูลข้อความ/Feature	สำรวจการกระจายและ การรวมกลุ่ม
Token Length CDF	13	Token Length	วิเคราะห์ความยาวของ ข้อความ

Visualization	แผนภูมิ	ข้อมูลที่ใช้	จุดประสงค์
Missing Value Analysis	14	Dataset	ตรวจสอบความสมบูรณ์ ของข้อมูล

3.5 การวิเคราะห์และตีความ Visualization

หลังจากสร้าง Visualization แต่ละตัว จะพิจารณารูปแบบที่ปรากฏและความสัมพันธ์กับตัวแปรที่ใช้ในการวิเคราะห์ โดยไม่พิจารณากราฟแยกจากบริบทของข้อมูล ตัวอย่างเช่น Jaccard Similarity ใช้เปรียบเทียบความคล้ายของ Keywords ระหว่าง Subjects ขณะที่ Publication Trend ใช้ดูการเปลี่ยนแปลงของจำนวนบทความตามเวลา

สำหรับ Visualization ด้าน ML Readiness จะใช้ผลการวิเคราะห์เพื่อประกอบการตัดสินใจเกี่ยวกับการเตรียมข้อมูลก่อนเข้าสู่ Machine Learning และ Text Embedding

3.6 การคัดเลือกข้อมูลสำหรับ Text Embedding

จากผลการทำ EDA ได้พิจารณาเลือกข้อมูลข้อความที่มีเนื้อหาเชิง Semantic สำหรับสร้าง Text Embedding จำนวน 4 คอลัมน์

คอลัมน์	เหตุผลที่เลือก	ความสมบูรณ์ของข้อมูล
Title	สื่อใจความสำคัญของงานวิจัยแบบกระชับที่สุด	100.0%
Abstract	ให้บริบทและรายละเอียดของงานวิจัย	99.83%
Author Keywords	คำสำคัญที่ผู้เขียนกำหนดเอง สะท้อนประเด็นหลัก	95.80%
Index Keywords	คำสำคัญที่จัดหมวดหมู่มาตรฐาน โดย Scopus	ใช้เสริมมุมมองเชิงหมวดหมู่

python

```
def combine_text(row):
    parts = []
    if pd.notna(row.get("Title")) and str(row["Title"]).strip():
        parts.append(f"Title: {row['Title']}")
    if pd.notna(row.get("Abstract")) and str(row["Abstract"]).strip():
        parts.append(f"Abstract: {row['Abstract']}")
    if pd.notna(row.get("Author Keywords")) and str(row["Author Keywords"]).strip():
        parts.append(f"Author keywords: {row['Author Keywords']}")
    if pd.notna(row.get("Index Keywords")) and str(row["Index Keywords"]).strip():
        parts.append(f"Index keywords: {row['Index Keywords']}")
    return "\n".join(parts)
```

การเลือกใช้หลายคอลัมน์ร่วมกันช่วยให้ข้อมูลที่นำเข้าสู่โมเดลครอบคลุมทั้งหัวข้อ รายละเอียด และคำสำคัญของบทความ

3.7 การรวมข้อมูลข้อความ

ข้อมูลจากทั้ง 4 คอลัมน์ถูกนำมารวมเป็นข้อความเดียวต่อบทความ โดยกำหนด Label เพื่อระบุประเภทของข้อมูล เช่น Title:, Abstract:, Author Keywords: และ Index Keywords: หากคอลัมน์ใดไม่มีข้อมูล จะกรอกร่องส่วนดังกล่าวออกก่อนนำข้อความไปประมวลผล เพื่อไม่ให้เกิด Label ที่ไม่มีเนื้อหาตามหลัง

3.8 การกำหนดความยาวของข้อความ

ก่อนนำข้อความเข้าสู่โมเดล จะทำ Tokenization และกำหนดความยาวสูงสุดของ Input ตามข้อจำกัดของโมเดลที่ใช้ โดยกำหนดความยาวสูงสุดที่ 512 Tokens ผลจากการวิเคราะห์ Token Length CDF ถูกนำมาใช้ประกอบการตัดสินใจเกี่ยวกับการกำหนดความยาวของข้อความ

3.9 การสร้าง Text Embedding

ใช้โมเดล SPECTER2 โดยใช้ allenai/specter2_base ร่วมกับ proximity adapter เพื่อสร้าง Representation ของบทความวิจัย ข้อความที่ผ่านการเตรียมแล้วจะถูกส่งเข้าสู่ Tokenizer และโมเดล จากนั้นสร้างเวกเตอร์แทนบทความแต่ละบทความ

การประมวลผลข้อมูลทั้งหมดดำเนินการเป็น Batch เพื่อให้สามารถประมวลผลบทความจำนวน 6,000 รายการได้อย่างเป็นระบบ

```
python
```

```
tokenizer = AutoTokenizer.from_pretrained("allenai/specter2_base")
model = AutoAdapterModel.from_pretrained("allenai/specter2_base")
model.load_adapter("allenai/specter2", source="hf", load_as="proximity", set_active=True)
model = model.to(device)
model.eval()
```

3.10 การจัดเก็บ Feature Vector

Feature Vector ที่ได้ถูกจัดเก็บในไฟล์ `text_embeddings.npy` และ Metadata ถูกจัดเก็บใน `text_embeddings_meta.csv` ไฟล์ Metadata ใช้เก็บข้อมูลที่ช่วยเชื่อมโยง Feature Vector กลับไปยังบทความต้นฉบับ เช่น `row_id`, `EID`, `Title` และ `Subject`

3.11 การตรวจสอบผลลัพธ์

หลังจากสร้าง Text Embedding จะตรวจสอบจำนวนข้อมูล ขนาดของ Feature Vector และความสมบูรณ์ของค่าที่ได้ เพื่อให้มั่นใจว่าสามารถนำข้อมูลไปใช้ใน Machine Learning ต่อไปได้

ผลลัพธ์ที่คาดหวังคือ Feature Matrix ที่มีจำนวนแถวเท่ากับจำนวนบทความ และจำนวนคอลัมน์เท่ากับจำนวนมิติของ Embedding

บทที่ 4

ผลการดำเนินงาน

4.1 ผลการวิเคราะห์ข้อมูลเบื้องต้น

จาก Dataset พบว่ามีบทความวิจัยทั้งหมด 6,000 บทความ ครอบคลุม 10 Subjects โดยแต่ละ Subject มีจำนวน 600 บทความ

ข้อมูลประกอบด้วยทั้งข้อมูลข้อความและข้อมูลเชิงโครงสร้าง ทำให้สามารถนำมาวิเคราะห์ได้หลายด้าน ตั้งแต่ลักษณะของภาษา แนวโน้มการตีพิมพ์ รูปแบบการเผยแพร่ ความร่วมมือของผู้เขียน และความพร้อมสำหรับ Machine Learning

4.2 ผลการวิเคราะห์ด้าน NLP & Language

4.2.1 ผล Jaccard Similarity

ผลจาก Jaccard Similarity Heatmap แสดงความคล้ายของ Keywords ระหว่างแต่ละ Subject โดยค่า Jaccard ที่สูงหมายถึงมี Keywords ที่ใช้ร่วมกันมากกว่า

จากผลการวิเคราะห์พบว่า Artificial Intelligence และ Information Systems มีความทับซ้อนของ Keywords สูงที่สุด โดยมีค่า Jaccard ประมาณ 0.1543 ในขณะที่ Computational Theory and Mathematics มีความทับซ้อนกับ Subjects อื่นในระดับค่อนข้างต่ำ ผลดังกล่าวแสดงให้เห็นว่าแต่ละ Subject มีทั้งส่วนของเนื้อหาที่เกี่ยวข้องกันและคำศัพท์เฉพาะทางที่แตกต่างกัน

4.2.2 ผล Type-Token Ratio

ผลการวิเคราะห์ TTR พบว่า Human-Computer Interaction มีค่า TTR สูงที่สุดประมาณ 0.1253 ขณะที่ Computer Vision and Pattern Recognition มีค่าต่ำที่สุดประมาณ 0.0944 ผลดังกล่าวสะท้อนให้เห็นว่าความหลากหลายของคำศัพท์ใน Abstract แตกต่างกันระหว่าง Subjects

4.2.3 ผล Bigram Frequency

ผลการวิเคราะห์ Bigram Frequency พบคำที่ปรากฏบ่อยในแต่ละ Subject เช่น computer aided, aided design, cad models และ real time คำเหล่านี้ช่วยแสดงลักษณะของคำศัพท์และวลีที่เกี่ยวข้องกับหัวข้อวิจัยในแต่ละสาขา และสามารถใช้เป็นข้อมูลประกอบการทำความเข้าใจลักษณะเชิง Semantic ของ Dataset

4.3 ผลการวิเคราะห์ด้าน Temporal Trends

4.3.1 ผล Publication Trend

Publication Trend แสดงจำนวนบทความในแต่ละปีและเปรียบเทียบระหว่าง Subjects จากการวิเคราะห์พบว่าบทความจำนวนมากกระจุกตัวในช่วงปี 2024–2025 โดยเฉพาะใน Artificial Intelligence, Computer Networks and Communications และ Computer Vision and Pattern Recognition ผลดังกล่าวแสดงให้เห็นการกระจายตัวของข้อมูลตามเวลาและทำให้สามารถเปรียบเทียบแนวโน้มการเผยแพร่ระหว่าง Subjects ได้

4.3.2 ผล Emerging Keywords

ผลการวิเคราะห์ Emerging Keywords แสดง Keywords ที่มีการเปลี่ยนแปลงตามช่วงเวลา โดยพบคำที่มีแนวโน้มเพิ่มขึ้น เช่น fusion, vision, llms และ llm ผลดังกล่าวสะท้อนให้เห็นว่าหัวข้อและคำศัพท์ที่ใช้ในงานวิจัยมีการเปลี่ยนแปลงตามช่วงเวลา

4.3.3 ผล Citation Velocity

Citation Velocity แสดงรูปแบบของ Citation เมื่อพิจารณาพร้อมกับปีที่เผยแพร่ การวิเคราะห์ช่วยให้เห็นความแตกต่างของจำนวน Citation ในบทความจากช่วงเวลาที่แตกต่างกัน และช่วยให้เข้าใจการกระจายของ Citation ใน Dataset

4.4 ผลการวิเคราะห์ด้าน Publication & Venues

4.4.1 ผล Document Type Distribution

ผลการวิเคราะห์ Document Type พบว่าแต่ละ Subject มีสัดส่วนประเภทเอกสารแตกต่างกัน Human-Computer Interaction มีสัดส่วน Conference Paper สูง ขณะที่ Computer Networks and

Communications มีสัดส่วน Journal Article สูงกว่า ผลดังกล่าวแสดงให้เห็นรูปแบบการเผยแพร่ผลงานวิจัยที่แตกต่างกันระหว่างสาขา

4.4.2 ผล Top Publication Sources

จากการวิเคราะห์แหล่งตีพิมพ์ พบว่า Proceedings of SPIE มีจำนวนบทความสูงที่สุด รองลงมาคือ UbiComp Companion 2025 และ Engineering Applications of AI ผลนี้ช่วยให้เห็นว่า Dataset มีการกระจายของบทความไปยังแหล่งตีพิมพ์หลายประเภท และมีบางแหล่งที่มีจำนวนบทความมากกว่าแหล่งอื่น

4.4.3 ผล Open Access vs Citation

ผลการเปรียบเทียบ Open Access กับ Citation พบว่ากลุ่ม Open Access มีการกระจายของ Citation ไปยังระดับที่สูงกว่ากลุ่ม Subscription อย่างไรก็ตาม ผลดังกล่าวเป็นเพียงความสัมพันธ์ที่พบใน Dataset และไม่สามารถสรุปได้โดยตรงว่า Open Access เป็นสาเหตุที่ทำให้ Citation สูงขึ้น

4.5 ผลการวิเคราะห์ด้าน Collaboration

4.5.1 ผล Author Count Distribution

ผลการวิเคราะห์จำนวนผู้เขียนพบว่าในหลาย Subjects จำนวนผู้เขียนมีค่ามัธยฐานประมาณ 4–5 คน ขณะที่บาง Subjects มีค่ามัธยฐานต่ำกว่า นอกจากนี้ยังพบ Outlier ที่มีจำนวนผู้เขียนสูงในบางบทความ แสดงให้เห็นว่ารูปแบบการทำงานร่วมกันของผู้วิจัยมีความแตกต่างกัน

4.5.2 ผล Author Count vs Citation

ผลการวิเคราะห์แสดงแนวโน้มว่าบทความที่มีจำนวนผู้เขียนมากขึ้นมีค่าเฉลี่ย Citation สูงขึ้นใน Dataset อย่างไรก็ตาม ความสัมพันธ์ดังกล่าวไม่สามารถใช้สรุปเชิงเหตุและผลได้ เนื่องจาก Citation อาจได้รับอิทธิพลจากปัจจัยอื่นร่วมด้วย

4.6 ผลการวิเคราะห์ด้าน ML Readiness

4.6.1 ผล t-SNE Semantic Visualization

ผลจาก t-SNE แสดงการกระจายตัวของข้อมูลข้อความในพื้นที่ 2 มิติ จาก Visualization พบว่าบาง Subjects มีการรวมกลุ่มของข้อมูลค่อนข้างชัดเจน ขณะที่บาง Subjects มีการกระจายและเกิดการทับซ้อนกัน

ผลดังกล่าวสนับสนุนว่าข้อมูลข้อความมีลักษณะเชิง Semantic ที่สามารถนำไปสร้าง Feature สำหรับ Machine Learning ได้

4.6.2 ผล Token Length CDF

ผลการวิเคราะห์ Token Length CDF แสดงการกระจายสะสมของความยาวข้อความ จากผลการวิเคราะห์พบว่าประมาณ 95% ของ Abstract มีความยาวไม่เกินประมาณ 300 คำ ผลนี้ถูกนำมาใช้ประกอบการกำหนดแนวทางในการเตรียมข้อความก่อนเข้าสู่โมเดล Text Embedding

4.6.3 ผล Missing Value Analysis

ผลการตรวจสอบ Missing Value พบว่าความสมบูรณ์ของข้อมูลแต่ละคอลัมน์ไม่เท่ากัน โดย Abstract มีความสมบูรณ์สูง ขณะที่ Author Keywords มีข้อมูลที่ขาดหายมากกว่าในบาง Subject ผลดังกล่าวมีผลต่อการเลือกข้อมูลสำหรับ Text Embedding เนื่องจากไม่ควรพึ่งพาคอลัมน์ที่มี Missing Value สูงเพียงคอลัมน์เดียว

4.7 ผลการคัดเลือกข้อมูลสำหรับ Text Embedding

จากผลการวิเคราะห์ EDA ได้เลือกข้อมูลข้อความ 4 คอลัมน์ ได้แก่

- Title
- Abstract
- Author Keywords
- Index Keywords

เหตุผลสำคัญคือข้อมูลทั้ง 4 ส่วนมีเนื้อหาเชิง Semantic และช่วยอธิบายบทความในมุมมองที่แตกต่างกัน โดย Title ให้ความสำคัญ Abstract ให้รายละเอียดของงานวิจัย และ Keywords ช่วยระบุประเด็นสำคัญของบทความ

ข้อมูลทั้ง 4 คอลัมน์ถูกนำมารวมเป็นข้อความเดียวต่อบทความก่อนนำเข้าสู่โมเดล

4.8 ผลการสร้าง Text Embedding

หลังจากนำข้อความเข้าสู่กระบวนการสร้าง Text Embedding ด้วย SPECTER2 ได้ผลลัพธ์เป็น Feature Vector สำหรับบทความทั้ง 6,000 บทความ จากการตรวจสอบไฟล์ `text_embeddings.npy` พบว่ามีขนาด

$$6,000 \times 768$$

หมายความว่าแต่ละบทความถูกแทนด้วย Feature Vector จำนวน 768 มิติ และมี Feature Vector ทั้งหมด 6,000 รายการ ข้อมูลที่ได้สามารถเขียนในรูปแบบเมทริกซ์ได้ดังนี้

$$X \in \mathbb{R}^{6000 \times 768}$$

โดยแต่ละแถวของเมทริกซ์แทนบทความหนึ่งบทความ และแต่ละคอลัมน์แทนค่าคุณลักษณะหนึ่งมิติของ Embedding

4.9 ผลการตรวจสอบ Feature Vector

จากการตรวจสอบข้อมูลใน `text_embeddings.npy` พบว่า Feature Vector มีชนิดข้อมูลเป็น `float32`

นอกจากนี้ไม่พบค่า `NaN` และ `Inf` ใน Embedding Matrix จึงสามารถนำข้อมูลไปใช้เป็น Input สำหรับกระบวนการ Machine Learning ในขั้นตอนต่อไปได้

Metadata ถูกจัดเก็บแยกใน `text_embeddings_meta.csv` ซึ่งสามารถใช้เชื่อมโยง Feature Vector กลับไปยังข้อมูลบทความต้นฉบับผ่านข้อมูล เช่น `row_id`, `EID`, `Title` และ `Subject`

4.10 สรุปผลการดำเนินงาน

การดำเนินงานเริ่มจากข้อมูลบทความวิจัยจำนวน 6,000 บทความ จาก 10 Subjects และดำเนินการ EDA ใน 5 Dimensions ได้แก่ NLP & Language, Temporal Trends, Publication & Venues, Collaboration และ ML Readiness

ผลการวิเคราะห์จาก Visualization ช่วยให้เห็นลักษณะของข้อมูลในหลายมิติ ทั้งความคล้ายของ Keywords ความหลากหลายของคำศัพท์ แนวโน้มการตีพิมพ์ รูปแบบการเผยแพร่ ความร่วมมือของผู้เขียน และความพร้อมสำหรับ Machine Learning

จากผล EDA ได้เลือกข้อมูลข้อความ 4 ส่วน ได้แก่ Title, Abstract, Author Keywords และ Index Keywords สำหรับนำไปสร้าง Text Embedding

ผลลัพธ์สุดท้ายคือ Feature Matrix ขนาด **6,000 × 768** ซึ่งสามารถนำไปใช้เป็น Feature สำหรับงาน Machine Learning ต่อไป เช่น Classification, Clustering และ Similarity Analysis

ดังนั้น ผลการดำเนินงานสามารถตอบโจทย์ของการวิเคราะห์ได้ทั้ง 3 ส่วน คือ การอธิบายกระบวนการ EDA การอธิบายความหมายและความสัมพันธ์ของ Visualization แต่ละตัว และการสรุปข้อมูลที่เหมาะสมสำหรับนำไปสร้าง Text Embedding หรือ Feature Vector