

 Scopus Bibliometrics & Machine Learning Pipeline

การวิเคราะห์ข้อมูล Scopus & ความพร้อมสู่ Machine Learning

กระบวนการสำรวจข้อมูลเชิงลึก 5 มิติ (EDA), การทำ Data Visualization
และการสกัดคุณลักษณะด้วย SPECTER2 Embedding เพื่อฝึกฝนโมเดล AI

 Project Architecture

ภาพรวมข้อมูลและการวิเคราะห์ 5 มิติ

ฐานข้อมูลงานวิจัย Scopus จำนวน 6,000 ระเบียน ครอบคลุม 10 สาขาวิชาหลักทางวิทยาการคอมพิวเตอร์และเทคโนโลยี (ปี 2020 – 2026) ผ่านการตรวจสอบคุณภาพด้วยระดับความสมบูรณ์ 96.4%

กระบวนการเตรียมข้อมูล & ทำความสะอาด



1. Data Integration & Cleaning

การรวมชุดข้อมูลดิบ: รวบรวมไฟล์ CSV จาก 10 สาขาย่อย และทำ Standardization ชื่อ Subject ให้เป็นหมวดหมู่มาตรฐาน

Type Coercion: แปลงค่าเชิงตัวเลข เช่น Year และ Cited by พร้อมกำหนดค่าเริ่มต้นเพื่อป้องกัน Type Mismatch

Text Normalization: กรองคำว่างและจัดการ Title, Abstract, Author Keywords ให้พร้อมสำหรับการวิเคราะห์ข้อความ



2. Multi-Field Feature Engineering

Tokenization & N-grams: สกัดคำศัพท์ภาษาอังกฤษ (Regex Filter ความยาว ≥ 3 อักษร) และกำจัด Stop words เชิงวิชาการ

Author Grouping: จัดกลุ่มขนาดทีมผู้เขียนออกเป็น 5 ระดับ (เดี่ยว, เล็ก, กลาง, ใหญ่, ใหญ่มาก) เพื่อวิเคราะห์ผลกระทบ

OA Status Labeling: แยกประเภทสิทธิ์การเข้าถึงแบบ Open Access และ Subscription เพื่อวัดความได้เปรียบเชิงอ้างอิง

DIMENSION 1

มิติภาษาและความหลากหลายของคลังคำ (NLP)



💡 **ข้อค้นพบด้าน NLP:** Type-Token Ratio (TTR) สะท้อนความหลากหลายของคำศัพท์ โดยกลุ่ม HCI มีความหลากหลายของคำศัพท์สูงสุด (0.1253) ในขณะที่ Computer Vision มีคำศัพท์เฉพาะกลุ่มที่เกิดซ้ำบ่อยกว่า ทั้งนี้ Jaccard Overlap ยืนยันว่าแต่ละสาขามีเอกลักษณ์ของชุด Keyword ชัดเจน เหมาะแก่การทำ Text Classification

DIMENSION 2

แนวโน้มเชิงเวลาและคำสำคัญอุบัติใหม่



↗ Top Emerging Keywords

- | | |
|-------------------------|-------|
| 1. Fusion / Multimodal | +687x |
| 2. Vision / Transformer | +502x |
| 3. LLMs / GenAI | +484x |
| 4. Federated / Privacy | +395x |

📈 **การเติบโตและการเปลี่ยนผ่าน:** งานวิจัยพุ่งสูงสูงสุดในปี 2025 โดยมีหัวข้อ Multimodal Fusion, LLMs และ Privacy-Preserving AI เป็นแกนนำในการขับเคลื่อนเทคโนโลยี

แหล่งตีพิมพ์และผลกระทบของ Open Access



- **Conference Papers (58%)**— เด่นมากในสาขา CS/Software
- **Journal Articles (30%)**— เด่นในสายทฤษฎีและคณิตศาสตร์
- **Book Chapters & Reviews (8%)**— งานสรุปวรรณกรรม
- **Others / Letters (4%)**— รายงานเบื้องต้น

 **Open Access Citation Advantage:** การวิเคราะห์การกระจายตัวแบบ Violin Plot พบว่าบทความ Open Access ได้รับคำมัยฐานและค่าเฉลี่ยการอ้างอิงสูงกว่ากลุ่ม Subscription อย่างมีนัยสำคัญ

เครือข่ายความร่วมมือและขนาดทีมวิจัย

3.68

Citations เฉลี่ย (>10 คน)

0.85

Citations เฉลี่ย (ผู้เขียนเดี่ยว)

4.3x

อัตราการเติบโตของการอ้างอิง

68%

บทความที่มีผู้เขียน 3–5 คน

Team Size & Impact Correlation

การวิเคราะห์ความสัมพันธ์ระหว่างจำนวนผู้เขียนต่อบทความ (Co-authorship Network) พบว่า:

-  งานวิจัยแบบทีมขนาดใหญ่ (>10 คน) ได้รับการอ้างอิงเฉลี่ย **3.68 ครั้ง** เทียบกับผู้เขียนเดี่ยวที่ได้รับเพียง **0.85 ครั้ง**
-  โครงสร้างเครือข่ายสะท้อนลักษณะความร่วมมือแบบข้ามสถาบันและข้ามประเทศ โดยเฉพาะในโครงการ AI ขนาดใหญ่

การประเมินคุณภาพและความสมบูรณ์ของข้อมูล

ฟิลด์ข้อมูล (Feature Field)	อัตราความสมบูรณ์ (%)	อัตราสูญหาย (Missing %)	กลยุทธ์การจัดการข้อมูล (Imputation Strategy)	สถานะความพร้อม
Title / Document Title	100.0%	0.00%	คงสภาพข้อความเดิม 100% สำหรับการทำ Embedding	สมบูรณ์แบบ
Abstract	99.83%	0.17%	เติมข้อความว่าง "" หรือตัดทิ้งหากไม่มีข้อมูลหลัก	พร้อมใช้งาน
Author Keywords	95.80%	4.20%	ดึงคำสำคัญจาก Title/Abstract หรือใช้ Unknown	ผ่านเกณฑ์
Cited by / Year	100.0%	0.00%	แปลงค่าตัวเลข (Numeric Imputation: 0, 2020)	พร้อมใช้งาน
Funding / Affiliations	86.20%	13.80%	แยกประมวลผลเป็น Categorical Flag หรือค่าว่าง	ต้องปรับแต่ง

🛡️ **ความพร้อมเชิงคุณภาพ:** ฟิลด์ข้อความหลัก (Title + Abstract + Keywords) มีความสมบูรณ์รวมกว่า **96.4%** มีความเสี่ยงการเกิด Information Loss ในระดับต่ำมาก

การทดสอบความพร้อมสำหรับ Machine Learning



t-SNE Semantic Separability

การลดมิติข้อมูล (2D Projection): ทดสอบเวกเตอร์ TF-IDF (300 มิติ) ด้วย t-SNE (Perplexity=30) พบการเกาะกลุ่มแยกตามสาขาอย่างชัดเจน

Cluster Separability: สาขาเฉพาะทาง เช่น *Computational Theory & Math* และ *Computer Vision* แยกตัวออกจากกลุ่มอื่น บ่งบอกว่าข้อมูลมีความ Discriminative Power สูง



Token Length CDF & Truncation

Cumulative Distribution (CDF): การแจกแจงสะสมความยาวคำในบทคัดย่อ พบว่า 95% ของบทคัดย่อมีความยาวไม่เกิน **350 คำ**

Max Length Optimization: การตั้งค่า `max_length = 512 tokens` ในโมเดล Transformer ครอบคลุมเนื้อหาได้ **99.9%** โดยไม่เกิด Information Truncation

การสกัด Embedding ด้วย SPECTER2



1. Multi-Field Concat

ผสานข้อมูลข้อความหลายฟิลด์เข้าด้วยกันตามรูปแบบมาตรฐานทางวิชาการ:

```
Title: ...  
Abstract: ...  
Author keywords: ...
```



2. SPECTER2 + Adapter

ใช้โมเดล `allenai/specter2_base` ร่วมกับ `proximity adapter` เพื่อจับความหมายเชิงบรรณานุกรมและโครงสร้างงานวิจัย



3. 768-D Feature Matrix

สร้างเวกเตอร์ Dense Embedding ขนาด **(6000, 768)** บันทึกลง `text_embeddings.npy` พร้อมไฟล์ Metadata เชื่อมโยง

⚡ **ประสิทธิภาพสูง:** การประมวลผลเป็น Batch (Batch Size = 16) บน GPU พร้อมดึง [CLS] token ให้ผลลัพธ์ที่เป็น Numerical Feature Vectors พร้อมป้อนเข้าโมเดลทันที

แนวทางการนำข้อมูลไปทรนโมเดล ML/DL

- ✓ **การจำแนกสาขาวิชาอัตโนมัติ (Subject Classification):** นำเวกเตอร์ 768 มิติไปทรนโมเดล Supervised Classifiers เช่น XGBoost, LightGBM, SVM หรือ MLP โดยใช้ค่า Subject เป็น Target Labels (Multi-class)
- 📍 **การจัดกลุ่มและการสร้างกราฟความรู้ (Clustering & Graph Analysis):** นำ Embedding ไปทำ K-Means, HDBSCAN หรือสร้าง Citation/Semantic Graph Network สำหรับการสืบค้นและจับคู่เอกสารที่ใกล้เคียงกัน
- 📈 **การทำนายผลกระทบงานวิจัย (Citation Impact Prediction):** พาสานเวกเตอร์ข้อความเข้ากับ Metadata (ปีที่ตีพิมพ์, จำนวนผู้เขียน, Open Access status) เพื่อทำนายอัตราการถูกอ้างอิง (Regression Task)
- 📌 **ระบบแนะนำบทความวิจัย (Paper Recommendation System):** ใช้ Cosine Similarity ระหว่างเวกเตอร์เพื่อค้นหาค้นหาบทความที่มีความคล้ายคลึงเชิงความหมายสูงสำหรับนักวิจัย

คำถามและข้อเสนอแนะ

ขอบคุณสำหรับการรับฟังการนำเสนอ



Scopus Bibliometric Project



EDA & ML Pipeline Ready